Nombre de la práctica	Pipeline Proyecto Final			No.	1
Asignatura:	Simulacion	Carrera:	INGENIERÍA EN SISTEMAS COMPUTACIONALES-3502	Duración de la práctica (Hrs)	5 horas

NOMBRE DEL ALUMNO: Francisco David Colin Lira
GRUPO: 3502

I. Competencia(s) específica(s):

Analiza, modela, desarrolla y experimenta sistemas productivos y de servicios, reales o hipotéticos, a través de la simulación de eventos discretos, para dar servicio al usuario que necesite tomar decisiones, con el fin de describir con claridad su funcionamiento, aplicando herramientas matemáticas.

Encuadre con CACEI: Registra el (los) atributo(s) de egreso y los criterios de desempeño que se evaluarán en la materia.

Encuadre con CACEI

No. atributo	Atributos de egreso del PE que impactan en la asignatura	No.Criterio	Criterios de desempeño	No. Indicador	Indicadores
1	El estudiante identificará los principios de las ciencias básicas para la resolución de problemas prácticos de ingeniería	CD1	Propone alternativas de solucion	I1	diseño algoritmico
				I2	empleo de formulas y funciones
2	el estudiante diseñará esquemas de trabajo y procesos, usando metodologías congruentes en la resolución de problemas de ingeniería en sistemas computacionales	CD1	identifica metodologías y procesos empleados en la resolución de problemas	I1	identificacion y reconocimiento de distintas metodologias para la resolucion de problemas.
				I2	Manejo de procesos especificos en la solucion de problemas y/o deteccion de necesidades.
		CD2	diseña soluciones a problemas, empleando metodologías apropiadas al area	I1	uso de metodologias para el modelado de la solucion de sistemas y aplicaciones
				I2	diseño algoritmico.

II. Lugar de realización de la práctica (laboratorio, taller, aula u otro):

- **Aula**

III. Material empleado:

- Equipo de cómputo
- Anaconda Navigator

IV. Desarrollo de la práctica:

Empezamos analizándo el dataset para ver que es lo que contiene y si es que tiene datos nulos para poder procesarlos.

Model of Heart Failure Prediction

About this Dataset

Context:

Cardiovascular diseases (CVDs) are the number 1 cause of death globally, taking an estimated 17.9 million lives each year, which accounts for 31% of all deaths worldwide. Four out of 5CVD deaths are due to heart attacks and strokes, and one-third of these deaths occur prematurely in people under 70 years of age. Heart failure is a common event caused by CVDs and this dataset contains 11 features that can be used to predict a possible heart disease.

People with cardiovascular disease or who are at high cardiovascular risk (due to the presence of one or more risk factors such as hypertension, diabetes, hyperlipidaemia or already established disease) need early detection and management wherein a machine learning model can be of great help.

Attribute Information

Age: age of the patient [years]

Sex: sex of the patient [M: Male, F: Female]

ChestPainType: chest pain type [TA: Typical Angina, ATA: Atypical Angina, NAP: Non-Anginal Pain, ASY: Asymptomatic]

RestingBP: resting blood pressure [mm Hg]

Cholesterol: serum cholesterol [mm/dl]

FastingBS: fasting blood sugar [1: if FastingBS > 120 mg/dl, 0: otherwise]

RestingECG: resting electrocardiogram results [Normal: Normal, ST: having ST-T wave abnormality (T wave inversions and/or ST elevation or depression of > 0.05 mV), LVH: showing probable or definite left ventricular hypertrophy by Estes' criteria]

MaxHR: maximum heart rate achieved [Numeric value between 60 and 202]

ExerciseAngina: exercise-induced angina [Y: Yes, N: No]

Oldpeak: oldpeak = ST [Numeric value measured in depression]

ST_Slope: the slope of the peak exercise ST segment [Up: upsloping, Flat: flat, Down: downsloping]

HeartDisease: output class [1: heart disease, 0: Normal]

Source This dataset was created by combining different datasets already available independently but not combined before. In this dataset, 5 heart datasets are combined over 11 common features which makes it the largest heart disease dataset available so far for research purposes. The five datasets used for its curation are:

Cleveland: 303 observations Hungarian: 294 observations Switzerland: 123 observations Long Beach VA: 200 observations Stalog (Heart) Data Set: 270 observations Total: 1190 observations Duplicated: 272 observations

Importamos la librerías que usaremos para realizar el análisis y creacionista del modelo:

Imports

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import LabelEncoder
```

Cargamos el dataset y mostramos una cuanta información.

Load DataSet

```
df = pd.read_csv("heart.csv")
```

```
df.head()
```

	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
0	40	M	ATA	140	289	0	Normal	172	N	0.0	Up	0
1	49	F	NAP	160	180	0	Normal	156	N	1.0	Flat	1
2	37	M	ATA	130	283	0	ST	98	N	0.0	Up	0
3	48	F	ASY	138	214	0	Normal	108	Y	1.5	Flat	1
4	54	M	NAP	150	195	0	Normal	122	N	0.0	Up	0

Verificamos el shape o dimensiones del dataset y tambien vemos un poco de la información que tiene el dataset

```
df.shape
```

```
(918, 12)
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 918 entries, 0 to 917
Data columns (total 12 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Age             918 non-null    int64
 1   Sex             918 non-null    object
 2   ChestPainType   918 non-null    object
 3   RestingBP       918 non-null    int64
 4   Cholesterol     918 non-null    int64
 5   FastingBS       918 non-null    int64
 6   RestingECG      918 non-null    object
 7   MaxHR           918 non-null    int64
 8   ExerciseAngina  918 non-null    object
 9   Oldpeak         918 non-null    float64
 10  ST_Slope        918 non-null    object
 11  HeartDisease    918 non-null    int64
dtypes: float64(1), int64(6), object(5)
memory usage: 86.2+ KB
```

Verificamos que ninguna característica del dataset conténga datos nulos

```
# Verifico si alguna columna contiene datos nulos
df.isnull().sum()
```

```
Age              0
Sex              0
ChestPainType    0
RestingBP        0
Cholesterol      0
FastingBS        0
RestingECG       0
MaxHR            0
ExerciseAngina   0
Oldpeak          0
ST_Slope         0
HeartDisease     0
dtype: int64
```

Ahora obtenemos la funciones matemáticas de cada característica del dataset.

```
df.describe()
```

	Age	RestingBP	Cholesterol	FastingBS	MaxHR	Oldpeak	HeartDisease
count	918.000000	918.000000	918.000000	918.000000	918.000000	918.000000	918.000000
mean	53.510893	132.396514	198.799564	0.233115	136.809368	0.887364	0.553377
std	9.432617	18.514154	109.384145	0.423046	25.460334	1.066570	0.497414
min	28.000000	0.000000	0.000000	0.000000	60.000000	-2.600000	0.000000
25%	47.000000	120.000000	173.250000	0.000000	120.000000	0.000000	0.000000
50%	54.000000	130.000000	223.000000	0.000000	138.000000	0.600000	1.000000
75%	60.000000	140.000000	267.000000	0.000000	156.000000	1.500000	1.000000
max	77.000000	200.000000	603.000000	1.000000	202.000000	6.200000	1.000000

Revisamos cuantas personas padecen de una enfermedad al corazon ya que esto es una información muy útil para nuestro modelo

```
# hacemos un conteo de cuantas personas tienen una enfermedad del corazon
df['HeartDisease'].value_counts()
```

```
HeartDisease
1    508
0    410
Name: count, dtype: int64
```

Creámoslas un histograma para solo hacer una visualización de los datos e identificar algunas características de estos como los numeros y asi ver que modelo puede servir, en este caso es un modelo de regresión logística

```
df.hist(figsize=(20,15))
plt.show()
```

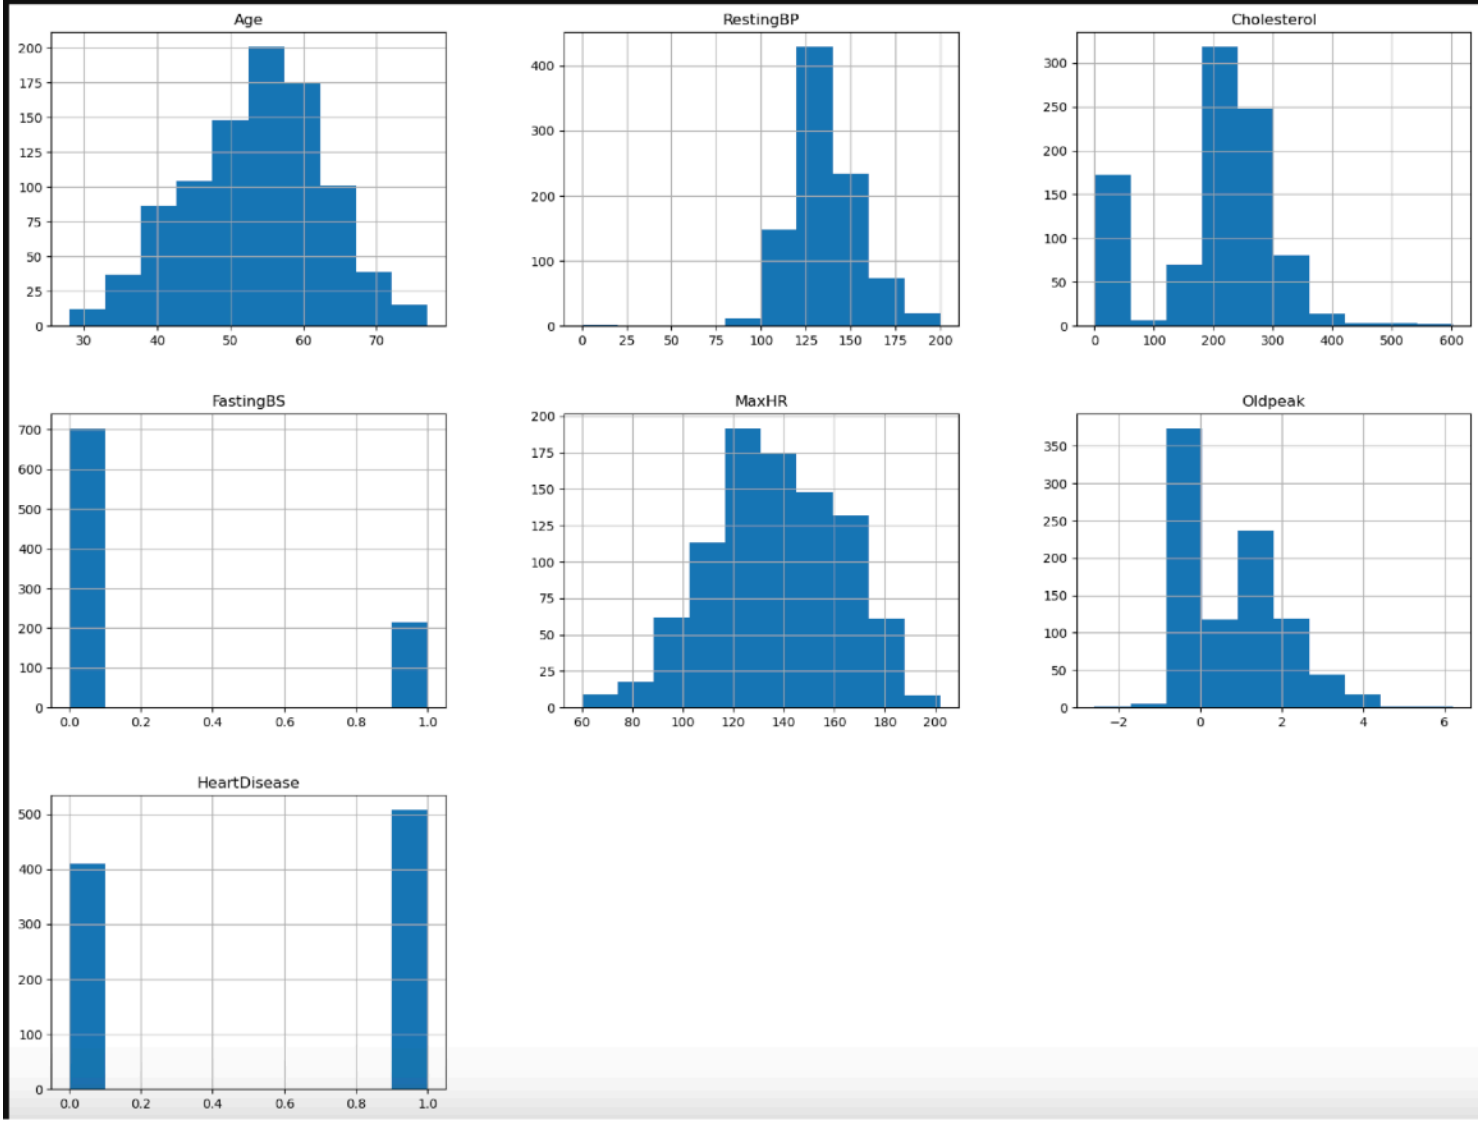

Empezamos a preprocesar la información en la cual utilizamos label encoder para transformar los datos a numeritos y esto nos ayude a que el modelo tenga un buen funcionamiento

Preprocessing data

```
lab = LabelEncoder()

# extraemos las columnas categoricas
obj = df.select_dtypes(include='object')
# extraemos las no categoricas
no_obj = df.select_dtypes(exclude='object')

# transformamos las categoricas a numericas
for i in range(0 , obj.shape[1]):
    obj.iloc[:,i] = lab.fit_transform(obj.iloc[:,i])

# concatenamos ambas tipos de columnas
df = pd.concat([obj , no_obj] , axis=1)

df
```

	Sex	ChestPainType	RestingECG	ExerciseAngina	ST_Slope	Age	RestingBP	Cholesterol	FastingBS	MaxHR	Oldpeak	HeartDisease
0	1	1	1	0	2	40	140	289	0	172	0.0	0
1	0	2	1	0	1	49	160	180	0	156	1.0	1
2	1	1	2	0	2	37	130	283	0	98	0.0	0
3	0	0	1	1	1	48	138	214	0	108	1.5	1
4	1	2	1	0	2	54	150	195	0	122	0.0	0
...	...	...	...	...	...	...	...	...	...	...	...	...
913	1	3	1	0	1	45	110	264	0	132	1.2	1
914	1	0	1	0	1	68	144	193	1	141	3.4	1
915	1	0	1	1	1	57	130	131	0	115	1.2	1
916	0	1	0	0	1	57	130	236	0	174	0.0	1
917	1	2	1	0	2	38	138	175	0	173	0.0	0

918 rows × 12 columns

Ahora creamos una función para poder dividir el dataset de una manera efectiva, en el cual tendremos 3 tipos de dataset, el dataset de entreno, de test y uno de validación para verificar que el modelo sea correcto, ademas con esto aseguramos un buen participando de los datos

```
# Construccion de una funcion que realice el particionado completo
def train_val_test_split(df, rsate = 42, shuffle = True, stratify = None):
    strat = df[stratify] if stratify else None
    train_set, test_set = train_test_split(
        df, test_size = 0.4, random_state = rsate, shuffle = shuffle, stratify = strat
    )
    strat = test_set[stratify] if stratify else None
    val_set, test_set = train_test_split(
        test_set, test_size = 0.5, random_state = rsate, shuffle = shuffle, stratify = strat
    )
    return (train_set, val_set, test_set)
```

Hacemos uso de la función de división del dataset y en cada tipo de dataset eliminamos la característica de HeartDisease para que este no la conozca ya que es la que nos ayudara a entrenar el modelo para despues hacer predicciones.

```
# Division del DataSet en los diferentes SubConjuntos
train_set, val_set, test_set = train_val_test_split(df)

# DataSet General
X_df = df.drop("HeartDisease", axis = 1)
y_df = df["HeartDisease"].copy()

# DataSet de entrenamiento
X_train = train_set.drop("HeartDisease", axis = 1)
y_train = train_set["HeartDisease"].copy()

# DataSet de Validacion
X_val = val_set.drop("HeartDisease", axis = 1)
y_val = val_set["HeartDisease"].copy()

# DataSet de test
X_test = test_set.drop("HeartDisease", axis = 1)
y_test = test_set["HeartDisease"].copy()
```

Ahora creamos el modelo de regresión logística y lo entrenamos con nuestro dataset de entreno

```
# Creamos nuestro modelo de regresion logistica y entrenamos con en dataset de entreno
model = LogisticRegression(max_iter=10000)
model.fit(X_train , y_train)
```

```
LogisticRegression
LogisticRegression(max_iter=10000)
```

Ahora que ya esta entrenado el modelo hacer predicciones con nuestro dataset de test y obtenemos la precisión de la predicción, luego obtenemos el f1 score que nos da un optimo porcentaje de precisión de nuestro modelo

```
# Hacemos la prediccion del dataset de prueba y verificamos la precision
y_pred = model.predict(X_test)
accuracy = accuracy_score(y_test , y_pred)
print('Precision:' , accuracy)
```

```
Precision: 0.875
```

```
from sklearn.metrics import f1_score
print("F1 score: ", f1_score(y_test, y_pred))
```

```
F1 score:  0.8909952606635072
```

Ahora mostraremos la matriz confusión con los falsos verdaderos y verdaderos, para asi ver que tanto nuestro modelo esta clasificando los datos.

```
from sklearn.metrics import ConfusionMatrixDisplay

ConfusionMatrixDisplay.from_estimator(model, X_val, y_val, values_format = '3g')
```

```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at 0x15b1d6b50>
```

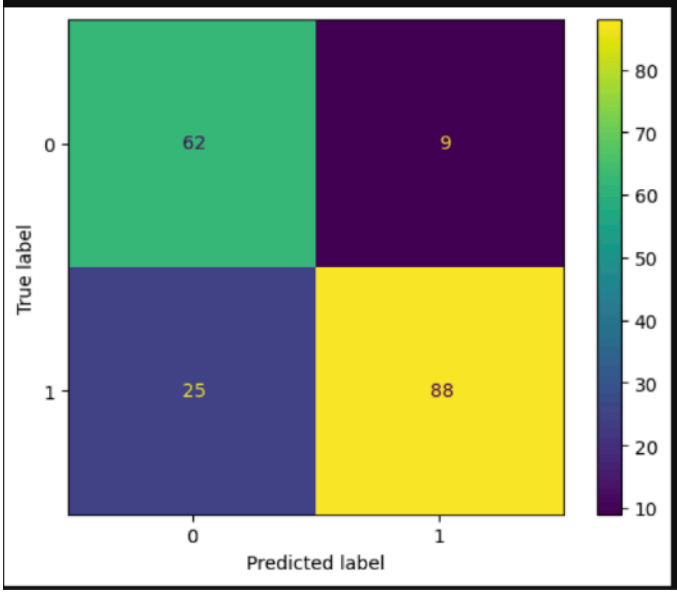

Ahora obtenemos las curvas de precisión y de el área bajo la curva (PR, ROC)

```
from sklearn.metrics import RocCurveDisplay
RocCurveDisplay.from_estimator(model, X_val, y_val)
```

```
<sklearn.metrics._plot.roc_curve.RocCurveDisplay at 0x15ca29730>
```

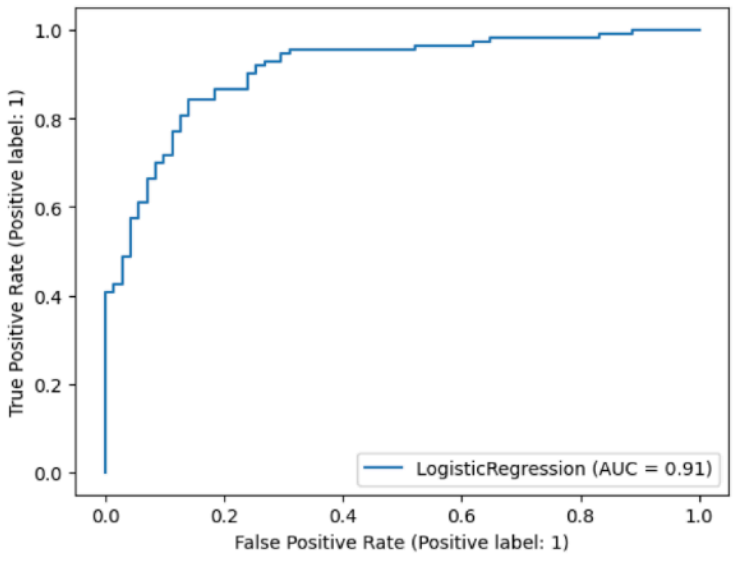


```
from sklearn.metrics import PrecisionRecallDisplay
PrecisionRecallDisplay.from_estimator(model, X_val, y_val)
```

```
<sklearn.metrics._plot.precision_recall_curve.PrecisionRecallDisplay at
```

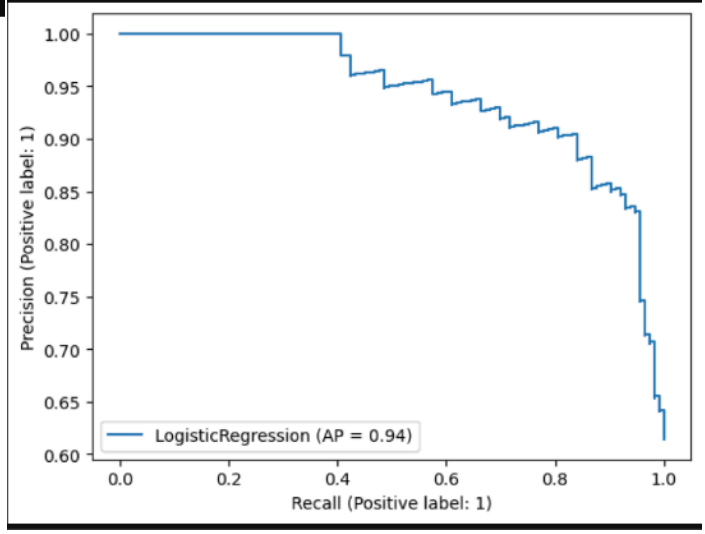

Ahora obtenemos la matriz de precisión con los datos de validación:

```
ConfusionMatrixDisplay.from_estimator(model, X_test, y_test, values_format = '3g' )
```

```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at 0x15cde87c0>
```

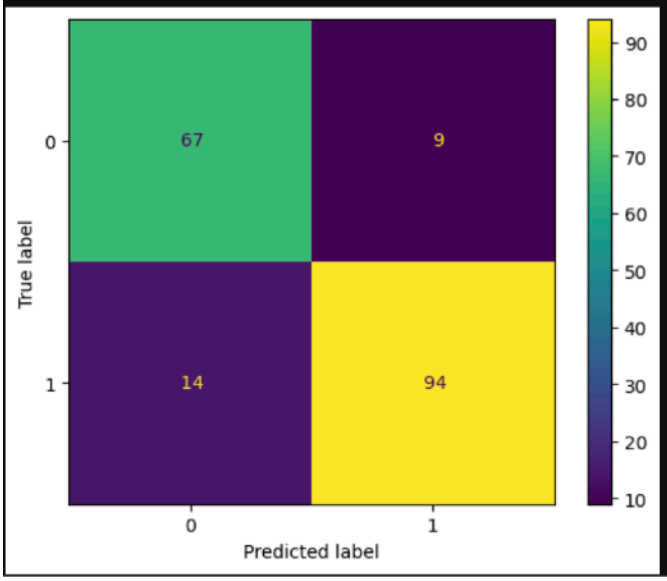

Ahora probaremos la aplicación, entrándoselo vemos que tenemos la métricas y datos de prueba:

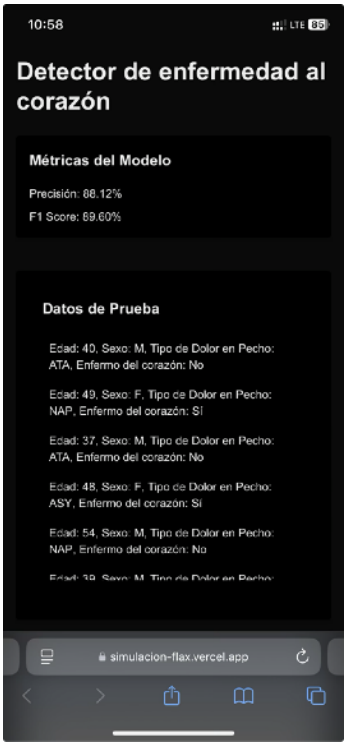

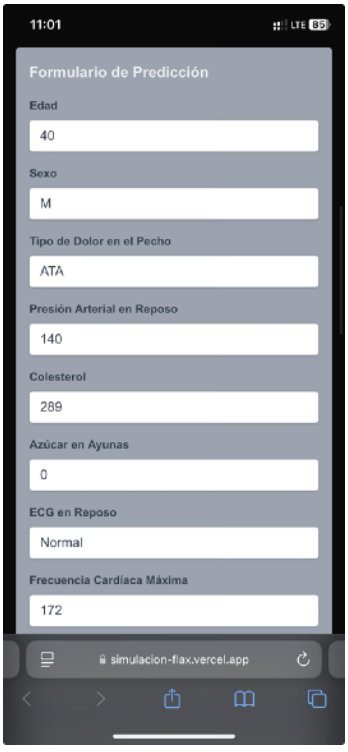

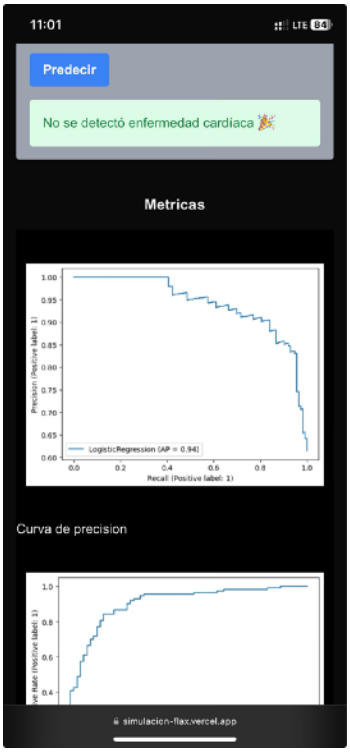

1.- En la primer pantalla podémos ver las métricas de precisión del modelo, ademas de ver algunos datos de prueba
2.- En la pantalla 2 seleccionamos un dato de prueba y nos da una previa de los datos y ademas se colocan automáticamente en el formulario
3.- Pantalla 3, tenemos el formulario donde se ingresan los datos y de aqui podemos predecir
4.- Pantalla 4, tenemos la respuesta de la predicción y podemos visualizar que no se detecto enfermedad al corazon, ademas abajo de esto tenemos las graficas de precisión de nuestro modelo asi como las matrices de

V. Conclusiones:

Durante la realización de este proyecto para mi fue algo complicado principalmente por encontrar un buen dataset que tuviera buenos datos, ademas que tuviera un fin practico tal vez a futuro este se le puede aplicar otros algoritmos o otro preprocesamiento de la información para que el modelo sea mas preciso ya que por ahora tiene 87%, ya que ahora en la actualidad algunas personas están enfermas del corazón y no lo saben y pues si ya tienen los datos que se piden en el formulario ya solo los ingresan y les da una respuesta, esto ayuda a identificar y poder hacer un tratamiento efectivo para prolongar la vida de el ser humano, a mi me pareció este proyecto muy interesante ya que pues puede ser de gran ayuda, ademas si me pareció agradable la implementación y me gusto realizar este tipo de proyecto.